
第六章：参数估计

6.1	点估计	2
6.1.1	矩估计方法	2
6.1.2	最大似然估计方法	7
6.1.3	点估计的优良准则	20

参数估计问题:

- 总体: $X \sim f_{\theta}(x)$, f 形式已知, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数
- 样本: X_1, \dots, X_n

利用样本对参数 θ 的作出估计或估计它们的某个已知函数 $g(\theta)$.

- **点估计**: 用样本的一个函数 $T(X_1, \dots, X_n)$ 去估计 $g(\theta)$
- **区间估计**: 用一个区间 (区域) 去估计 $g(\theta)$

6.1 点估计

根据样本 X_1, \dots, X_n 来估计参数 θ , 就是要构造适当的统计量 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$. 当有了样本 X_1, \dots, X_n 的值后, 就代入 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 中算出一个值, 用来作为 θ 的估计值. 为这样特定目的而构造的统计量 $\hat{\theta}$ 叫做 θ 的**估计量**. 由于参数 θ 是数轴上的一个点, 用 $\hat{\theta}$ 估计 θ , 等于用一个点去估计另一个点, 所以这样的估计叫做**点估计**.

求点估计的方法有多种, 下面介绍两种点估计方法:

6.1.1 矩估计方法

矩方法追溯到 19 世纪的**Karl Pearson**. 矩方法是基于一种简单的“替换”思想建立起来的一种估计方法. 其基本思想是用样本矩估计总体矩. 由大数律, 如果未知参数和总体的某个 (些) 矩有关系, 我们很自然的来构造未知参数的估计。

回忆一下以前关于矩的记法:

$$\text{样本}k\text{阶矩: } a_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad m_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

$$\text{总体}k\text{阶矩: } \alpha_k = EX^k \quad \mu_k = E(X - EX)^k$$

因此在 k 阶矩存在的情况下, 根据大数律有

$$a_k \xrightarrow{p} \alpha_k, \quad m_k \xrightarrow{p} \mu_k$$

从而我们可以使用 a_k, m_k 分别估计 α_k, μ_k , 进而得到 θ 的估计. 介绍如下: 假设总体 X 包含 k 个未知参数 $\theta = (\theta_1, \dots, \theta_k)$, 由方程组

$$\begin{cases} \alpha_1 = f_1(\theta_1, \dots, \theta_k) \\ \vdots \\ \alpha_k = f_k(\theta_1, \dots, \theta_k) \end{cases}$$

反解得到

$$\begin{cases} \theta_1 = g_1(\alpha_1, \dots, \alpha_k) \\ \vdots \\ \theta_k = g_k(\alpha_1, \dots, \alpha_k) \end{cases}$$

将其中的总体矩用相应的样本矩代替，则我们可以得到参数 $\theta_1, \dots, \theta_k$ 的一个估计：

$$\begin{cases} \hat{\theta}_1 = g_1(a_1, \dots, a_k) \\ \vdots \\ \hat{\theta}_k = g_k(a_1, \dots, a_k) \end{cases}$$

若要估计参数 $\theta_1, \dots, \theta_k$ 的某函数 $g(\theta_1, \dots, \theta_k)$ ，则用 $g(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 去估计它。

这里我们用的都是原点矩 α_k ，当然也可以使用中心矩 μ_k ，或者两个都使用。在这种情况下，只需要把相应的总体矩换成样本矩。我们称这种估计方法为矩估计法，得到的估计量称为矩估计量。**矩估计方法应用的原则是：能用低阶矩处理的就不用高阶矩。**

矩估计法的优点是简单易行, 有些情况下不需要事先知道总体是什么分布. 缺点是, 当总体类型已知时, 没有充分利用分布提供的信息. 一般场合下, 矩估计量不具有唯一性.

投掷一枚硬币, 为了解正面出现的概率, 现独立重复的投掷 n 次, 用 X_1, \dots, X_n 表示投掷结果. 显然此时总体 X 的分布为 $B(1, p)$, p 为感兴趣的量. 而 X_1, \dots, X_n 为样本, 则求参数 p 的矩估计量。

↑Example

↓Example

解: 由于 $EX = p$, 而样本均值 \bar{X} 收敛到总体均值 EX , 因此 p 的一个矩估计量为 $\hat{p} = \bar{X}$.

为考察某种考试成绩分布情况, 使用正态分布 $N(a, \sigma^2)$ 来作为总体 X 的分布. 现在从中随机调查 n 个人, 即样本为 X_1, \dots, X_n . 试求参数 a, σ^2 的矩估计量。

↑Example

↓Example

解: 由于

$$EX = a, \text{Var}(X) = \sigma^2$$

所以 a, σ^2 的一个矩估计量为

$$\hat{a} = \bar{X}, \hat{\sigma}^2 = m_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

我们知道 $ES^2 = \sigma^2$, 因此, σ^2 的另一个矩估计量为 $\hat{\sigma}^2 = S^2$.

6.1.2 最大似然估计方法

最大似然方法到目前为止应用最广的的点估计方法. 这种方法是基于如下的看法:

设样本 $X = (X_1, \dots, X_n)$ 有概率函数

$$f(x; \theta) = f(x; \theta_1, \dots, \theta_k)$$

Definition

这里参数 $\theta = (\theta_1, \dots, \theta_k) \in \Theta$, $x = (x_1, \dots, x_n)$ 为样本 X 的观察值. 当固定 x 时把 $f(x; \theta)$ 看成为 θ 的函数, 称为似然函数, 常记为 $L(x; \theta)$ 或 $L(\theta)$.

当固定参数 θ 时, $f(x; \theta)$ 可以看成是得到样本观察值 x 的可能性, 这样, 当把参数 θ 看成变动时, 也就得到“在不同的 θ 值下能观察到 x 的可能性大小, 即 $L(x; \theta)$ ”; 由于我们已经观察到了 x , 所以

使得能观察到 x 的可能性 $L(x; \theta)$ 最大的 θ 值, 看起来应该最像未知的 θ 。这个 θ 的值即称为 θ 最大似然估计值(看上去最有可能的)。我们先看一个例子:

从鱼池里随机捕捞 500 条鱼, 做好记号后重新放入鱼池中, 待充分混合后再捕捞 1000 条鱼, 结果发现其中有 72 条带有记号. 试问鱼池中可能有多少条鱼.

↑Example

↓Example

解: 先将问题一般化. 设池中有 N 条鱼, 其中 r 条做好记号. 鱼在鱼池里均匀. 随机捕捞 s 条, 发现 x 条有记号. 用上述信息来估计 N .

用 X 表示捕捞的 s 条鱼中带记号鱼的数目, 则

$$P(X = x) = \frac{C_{N-r}^{s-x} C_r^x}{C_N^s}.$$

目前发现在捕捞的 s 条鱼中有记号的鱼 x 条, 要寻求 N 取何值时, 使得观察到这个事件 $\{X = x\}$ 的可能性最大. 即 x 是固定的, N 是变化的, 记 $p(x; N) = P(X = x)$. 因为

$$g(N) := \frac{p(x; N)}{p(x; N-1)} = \frac{(N-s)(N-r)}{N(N-r-s+x)} = \frac{N^2 - N(s+r) + rs}{N^2 - N(r+s) + Nx},$$

当 $rs > Nx$ 时, $g(N) > 1$; $rs < Nx$ 时, $g(N) < 1$. 所以 $P(X = x)$ 在 $N = \frac{rs}{x}$ 附近达到最大, 注意到 N 只能取正整数, 故 N 的最可能的估计即最大似然估计为

$$\hat{N} = \left\lfloor \frac{rs}{x} \right\rfloor.$$

其中 $\lfloor \cdot \rfloor$ 表示下取整, 即小于该值的最大整数. 将题目中的数字代入,

$$\hat{N} = \left\lfloor \frac{500 \times 1000}{72} \right\rfloor = 6944.$$

即鱼池中的总的鱼数为 6694 条.

现给出最大似然估计的一般性定义:

设 $X = (X_1, \dots, X_n)$ 为从具有概率函数 $f_\theta(x)$ 的总体中抽取的样本, θ 为未知参数或者参数向量. $x = (x_1, \dots, x_n)$ 为样本的观察值. 若在给定 x 时, 值 $\hat{\theta} = \hat{\theta}(x)$ 满足下式

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(x; \theta)$$

Definition

则称 $\hat{\theta}$ 为参数 θ 的最大似然估计值, 而 $\hat{\theta}(X)$ 称为参数 θ 的最大似然估计量. 若待估参数为 θ 的函数 $g(\theta)$, 则 $g(\theta)$ 的最大似然估计量为 $g(\hat{\theta})$.

求最大似然估计值相当于求似然函数的最大值。在简单样本的情况下,

$$L(x; \theta) = \prod_{i=1}^n f_{\theta}(x_i)$$

而把似然函数的对数 $l(\theta) = \log L(\theta)$ 称为对数似然函数 (这是由于在一些情况下, 处理对数似然函数更方便)

当似然函数对变量 θ 单调时, 我们可以容易得到其最大值点. 反之当似然函数为非单调函数且对变量 θ 可微分时, 我们可以求其驻点: 令

$$\frac{dl(\theta)}{d\theta} = 0 \quad (\text{或者} \frac{dL(\theta)}{d\theta} = 0)$$

当 θ 为多维时, 比如 $\theta = (\theta_1, \dots, \theta_k)$ 时令

$$\frac{\partial l(\theta)}{\partial \theta_i} = 0 \quad (\text{或者} \frac{\partial L(\theta)}{\partial \theta_i} = 0) \quad i = 1, \dots, k$$

然后判断此驻点是否是最大值点。

设 X_1, \dots, X_n 为从总体 $X \sim N(a, \sigma^2)$ 中抽取的样本, 求参数 a, σ^2 的最大似然估计量。

↑Example

↓Example

解: 易得对数似然函数为

$$l(a, \sigma^2) = c - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2 - \frac{n}{2} \log(\sigma^2)$$

其中 c 是与参数无关的常数. 令

$$\begin{cases} \frac{\partial l(a, \sigma^2)}{\partial a} = 0 \\ \frac{\partial l(a, \sigma^2)}{\partial \sigma^2} = 0 \end{cases} \Rightarrow \begin{cases} a = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \\ \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases}$$

容易验证此驻点是唯一的最大值点, 因此得到 a, σ^2 的最大似然估计量:

$$\hat{a} = \bar{X} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

设总体 X 服从 $[a, b]$ 上的均匀分布, $a < b$, 求参数 a, b 的最大似然估计.

↑Example

↓Example

解: 易得似然函数为

$$L(a, b) = \frac{1}{(b-a)^n} \prod_{j=1}^n I(a \leq x_j \leq b) = \frac{1}{(b-a)^n} I(a \leq x_{(1)} \leq x_{(n)} \leq b).$$

于是对任何满足条件 $a \leq x_j \leq b$ 的 a, b 都有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n},$$

即似然函数 $L(a, b)$ 在 $a = x_{(1)}, b = x_{(n)}$ 时取到最大值. 于是 a, b 的最大似然估计量为 $\hat{a} = X_{(1)}, \hat{b} = X_{(n)}$.

设 X_1, \dots, X_n 为从具有如下形式密度的总体中抽取的样本:

↑Example

$$f(x; a, b) = \begin{cases} \frac{1}{b} \exp\{-\frac{x-a}{b}\} & , x > a \\ 0 & , x \leq a \end{cases}$$

求参数 a, b 的最大似然估计量.

↓Example

解: 易得似然函数为

$$L(a, b) = \prod_{i=1}^n f(x_i; a, b) = \frac{1}{b^n} \exp\{-\frac{1}{b} \sum_{i=1}^n (x_i - a)\} I(x_{(1)} > a)$$

在固定 b 时, 显然似然函数为 a 的单调增函数, 因此 $L(a)$ 的驻点为 $\hat{a} = x_{(1)}$ 。再令 $\frac{\partial L(a, b)}{\partial b} = 0$, 得到 $b = \frac{1}{n} \sum_{i=1}^n (x_i - x_{(1)})$, 容易验证此

解是最大值点。从而得到 a, b 的最大似然估计量:

$$\begin{cases} \hat{a} = X_{(1)} \\ \hat{b} = \frac{1}{n} \sum_{i=1}^n (X_i - X_{(1)}). \end{cases}$$

设总体 X_1, \dots, X_n 服从 0-1 分布 $B(1, p)$, $0 < p < 1$, 求参数 p 的最大似然估计.

↑Example

↓Example

解: 似然函数为

$$L(p) = \prod_{i=1}^n P(X_i = x_i) = p^{\sum x_i} (1-p)^{n-\sum x_i}$$

从而令 $\frac{\partial \log L(p)}{\partial p} = 0$ 得到

$$\sum_p x^i = \frac{n}{1-p} \sum x^i$$

因此 p 的似然估计为

$$\hat{p} = \frac{\sum_{i=1}^n X_i}{n}.$$

设总体 X_1, \dots, X_n 服从柯西分布 $f(x) = \frac{1}{\pi} \frac{1}{1+(x-\theta)^2}$, $x \in R, \theta \in R$, 求参数 θ 的最大似然估计.

↑Example

↓Example

解: 因为柯西分布不存在矩, 因此矩方法不适用. 其对数似然函数为

$$l(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i) = \sum_{i=1}^n \log \pi - \log(1 + (x_i - \theta)^2)$$

从而令 $\frac{\partial l(\theta)}{\partial \theta} = 0$ 得到

$$\sum_{i=1}^n \frac{2(x_i - \theta)}{1 + (x_i - \theta)^2} = 0$$

此方程没有显式解, 可以使用数值方法求解. 使用起来不太方便, 因此在应用中, 考虑到柯西分布的对称性, 使用样本中位数来估计 θ .

设 X_1, \dots, X_n 为从如下分布中抽取的简单样本, 求 θ 的最大似然估计.

↑Example

$$f(x) = \frac{1}{x!(2-x)!} [\theta^x (1-\theta)^{2-x} + \theta^{2-x} (1-\theta)^x], x = 0, 1, 2; \theta \in (0, \frac{1}{2})$$

↓Example

解: 由题设知 $f(x)$ 为离散型, 其分布律为

X	0	1	2
P	$\frac{1}{2}[(1-\theta)^2 + \theta^2]$	$2\theta(1-\theta)$	$\frac{1}{2}[(1-\theta)^2 + \theta^2]$

若直接从此分布出发, 则不能得到 θ 的最大似然估计的显式表达。为此, 我们重新参数化, 记 $\eta = 2\theta(1-\theta)$. 则由题设知 $\eta < 1/2$ 。则

X	0	1	2
P	$\frac{1}{2}(1-\eta)$	η	$\frac{1}{2}(1-\eta)$

再记 $n_i = \#\{X_1, \dots, X_n \text{ 中等于 } i \text{ 的个数}\}$, $i = 0, 1, 2$, 则得到似然函数为

$$L(\eta) = \left(\frac{1}{2}(1-\eta)\right)^{n_0} \eta^{n_1} \left(\frac{1}{2}(1-\eta)\right)^{n_2} = \left(\frac{1}{2}(1-\eta)\right)^{n-n_1} \eta^{n_1}$$

求解并注意 η 的上界即得到 η 的最大似然估计为

$$\hat{\eta} = \min\left\{\frac{n_1}{n}, \frac{1}{2}\right\}$$

再由 $\theta = \frac{1-\sqrt{1-2\eta}}{2}$ 得到 θ 的最大似然估计为

$$\hat{\theta} = \frac{1 - \sqrt{1 - 2\hat{\eta}}}{2}$$

6.1.3 点估计的优良准则

我们看到对同一个参数，有多个不同的估计量，因此，评选不同估计量的优劣性是需要考虑的。

1. 相合性

设总体分布依赖于参数 $\theta_1, \dots, \theta_k$, $g(\theta_1, \dots, \theta_k)$ 是待估参数函数。设 X_1, \dots, X_n 为自该总体中抽取的样本， $T(X_1, \dots, X_n)$ 为 $g(\theta_1, \dots, \theta_k)$ 的一个估计量，如果对任意的 $\epsilon > 0$ 和 $\theta_1, \dots, \theta_k$ 的一切可能值都有

$$\lim_{n \rightarrow \infty} P_{\theta_1, \dots, \theta_k} (|T(X_1, \dots, X_n) - g(\theta_1, \dots, \theta_k)| \geq \epsilon) = 0$$

我们则称 $T(X_1, \dots, X_n)$ 为 $g(\theta_1, \dots, \theta_k)$ 的一个 (弱)相合估计量 (Consistent Estimator)。

相合性是对一个估计量的最基本的要求，如果一个估计量没有相合性，那么无论样本大小多大，我们也不能把未知参数估计到任意预定的精度。这种估计量显然是不可取的。

矩估计量是满足相合性的，最大似然估计量在很一般的条件下也是满足相合性的。

2. 无偏性

设 $\hat{g}(X_1, \dots, X_n)$ 为待估参数函数 $g(\theta)$ 的一个估计量，若

$$E\hat{g}(X_1, \dots, X_n) = g(\theta)$$

则称 $\hat{g}(X_1, \dots, X_n)$ 为 $g(\theta)$ 的**无偏估计量 (Unbiased Estimator)**。无偏性的实际意义就是无系统误差。因此在有多个估计量可供选择时，我们优先考虑无偏估计量。

很多时候我们得到的估计量是有偏，例如正态总体的方差 σ^2 的最大似然估计量 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是有偏的， $E\hat{\sigma}^2 = \frac{n-1}{n}\sigma^2$ 。若以 $\frac{n}{n-1}$ 乘以 $\hat{\sigma}^2$ ，所得到的估计量就是无偏的。这种方法称为修正。

若某一参数存在多个无偏估计时，如何选择使用哪个估计量？人们又在无偏性的基础上增加对方差的要求。

3. 有效性

设 $\hat{g}_1(X_1, \dots, X_n)$ 和 $\hat{g}_2(X_1, \dots, X_n)$ 为待估参数函数 $g(\theta)$ 的两个不同的无偏估计量, 若对任意的 $\theta \in \Theta$, 有

$$\text{Var}(\hat{g}_1(X_1, \dots, X_n)) \leq \text{Var}(\hat{g}_2(X_1, \dots, X_n))$$

而且至少对某个 $\theta_0 \in \Theta$ 使得严格不等式成立。则称 \hat{g}_1 较 \hat{g}_2 有效。

设 X_1, \dots, X_n 为从如下分布中抽取的简单样本, 试证明样本方差为总体方差的无偏估计.

↑Example

↓Example

证: 显然

$$\begin{aligned} ES^2 &= E \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (E(X_i - EX_i + EX_i - \bar{X}))^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n [(E(X_i - EX_i))^2 - E(EX_i - \bar{X})^2] \\ &= \frac{1}{n-1} \sum_{i=1}^n [\sigma^2 - \sigma^2/n] = \sigma^2. \end{aligned}$$

设总体 X 服从 $(0, \theta)$ 上的均匀分布, $0 < \theta$, 求参数 θ 的最大似然估计是否为无偏估计.

↑Example

↓Example

解: 易得似然函数为

$$L(\theta) = \frac{1}{\theta^n} \prod_{j=1}^n I(0 \leq x_j \leq \theta) = \frac{1}{\theta^n} I(0 \leq x_{(1)} \leq x_{(n)} \leq \theta).$$

于是似然函数 $L(\theta)$ 在 $\theta = x_{(n)}$ 时取到最大值. 而 $X_{(n)}$ 的密度函数为

$$f(t) = \frac{nt^{n-1}}{\theta^n} I(0 < t < \theta).$$

因此

$$EX_n = \int_0^\theta tf(t)dt = \frac{n}{n+1} \theta.$$

即 θ 的最大似然估计量 $X_{(n)}$ 不是 θ 的无偏估计, 但 $\frac{n+1}{n} X_{(n)}$ 为 θ 的无偏估计量.

设 X_1, \dots, X_n 来自均值为 μ , 方差为 σ^2 的总体分布的简单样本, $\omega_1, \dots, \omega_n$ 为已知的非负权值, 且满足 $\sum \omega_i = 1$, 试比较 μ 的两个估计估计 \bar{X} 和 $\sum_{i=1}^n \omega_i X_i$.

↑Example

↓Example

解: 因为

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \text{Var}\left(\sum \omega_i X_i\right) = \sum_{i=1}^n \omega_i^2 \sigma^2,$$

所以

$$\text{Var}\left(\sum \omega_i X_i\right) \geq \text{Var}(\bar{X})$$

且等号成立当且仅当 $\omega_i = \frac{1}{n}$.

4. 渐近正态性

估计量是样本 X_1, \dots, X_n 的函数，其确切的分布一般不是容易得到。但是，许多形式很复杂的统计量 (未必是和)，当 n 很大时，其分布都渐近于正态分布，这个性质称为统计量的“渐近正态性”。

无偏性和有效性都是对固定的样本大小 n 而言的，这种性质称为估计量的“小样本性质”，而相合性和渐近正态性都是考虑在样本大小趋于无穷时的性质，这种性质称为“大样本性质”。

设从总体

↑Example

X	0	1	2	3
P	$\theta/2$	θ	$3\theta/2$	$1 - 3\theta$

抽取的一个简单样本 X_1, \dots, X_{10} 的观察值为 $(0, 3, 1, 1, 0, 2, 0, 0, 3, 0)$,

(1) 求 θ 的矩估计量 $\hat{\theta}_M$ 和最大似然估计量 $\hat{\theta}_L$, 并求出估计值。

(2) 上述估计量是否为无偏的? 若不是, 请作修正。

(3) 比较修正后的两个估计量, 指出那个更有效。

↓Example

由有效性的定义, 我们自然会问在一切可能的无偏估计里, 能否找到具有最小方差的无偏估计量? 如果存在这样的估计量, 我们称其为最小方差无偏估计量, 详细地可以参考课本。